État de l'Art : L'application des graphes de connaissances et de l'intelligence artificielle dans le secteur juridique

Carolina Courtin
Centre universitaire d'informatique, Université de Genève
Genève, Suisse
carolina.courtin@etu.unige.ch

Résumé

Le droit est un domaine exigeant en ressources, demandant souvent un investissement considérable en temps et en énergie. C'est pourquoi de nombreux chercheurs ont réfléchis à des manières d'améliorer les processus légaux en proposant des systèmes et approches nouvelles qui pourraient aider les juristes et autres acteurs légaux. Une approche particulièrement intéressante est l'intégration de technologies du web sémantique, plus particulièrement des graphes de connaissances au domaine légal. Ces technologies sont souvent associées à des techniques d'intelligence artificielle comme le machine learning pour compléter les systèmes à mettre en place et proposer des mécanismes plus robustes face aux attentes des utilisateurs.

Keywords

graphes de connaissances, LLM, machine learning, graph embedding, recommendation systems

1 Introduction

Le domaine du droit fait face à un grand nombre de défis divers tous les jours. Un problème majeur est la difficulté d'accès aux documents juridiques par les juristes mais aussi par les personnes qui ne sont pas familières à ce sujet. Ces complications peuvent avoir des répercussions importantes sur les processus légaux qui nécessitent la réunion de plusieurs de ces documents, comme des procès ou des procédures judiciaires complexes, où l'accès rapide et précis à l'information est crucial. Il y a en effet un besoin d'optimisation du temps et d'efficacité dans la recherche d'informations légales qui n'est pas permis en utilisant les ressources traditionnelles (comme les bases de données légales relationnelles ou les archives papier), qui sont souvent lentes, peu accessibles et difficiles à naviguer. C'est pourquoi un grand nombre de recherches se focalisent sur les diverses manières d'améliorer les processus légaux. Plusieurs pistes ont été étudiées, incluant des solutions très diverses comme l'utilisation de chatbot légaux ou l'introduction de technologies machine learning au domaine légal. Une approche particulière qui semble être prometteuse est la modélisation des données juridiques sous forme de graphes de connaissances. Les graphes de connaissances, à la différence des bases de données traditionnelles, permettent de représenter des relations établies entre divers documents. Dans le domaine légal, les décisions judiciaires et les concepts juridiques sont souvent interliés par des relations subtiles (par exemple, un article de loi renvoie à un précédent judiciaire ou un contrat fait référence à plusieurs lois). Les graphes de connaissances facilitent l'exploration de ces liens et permettent aux utilisateurs d'accéder à un ensemble de données beaucoup plus complet suite à une requête concernant un document particulier. Par exemple, un ancien procès peut être lié à un ensemble de lois utilisées pour le traiter, à des acteurs et à des jurisprudences. Tous ces éléments peuvent facilement être représentés dans un graphe de connaissances avec divers liens. De plus, l'utilisation de ces graphes implique très souvent d'intégrer des technologies d'intelligence artificielle pour produire des systèmes plus performants et de confiance. Cette utilisation se produit généralement lors de la traduction des documents légaux en graphes mais elle peut aussi intervenir à des étapes différentes. Cet état de l'art vise à comprendre diverses avancées faites au sein de cette thématique liant graphes de connaissances et intelligence artificielle appliqués au domaine juridique. Nous verrons que ces technologies sont appliquées de manière différente mais permettent généralement de produire des systèmes bien plus performants et utiles pour les juristes.

2 Utilisation de Large Language Models (LLMs) dans la construction d'un graphe de connaissances représentant des affaires judiciaires

Dans cette première section, nous discuterons de l'article intitulé *Construction of Knowledge Graph of Judicial Case Based on LLMs and Embedding Models* (Yicheng Shen, 2024)[2]. La problématique principale mise en avant par l'auteur de cet article est que le processus d'analyse des documents légaux, et plus précisément des affaires judiciaires antérieures, prend souvent beaucoup de temps du fait qu'elle doit être détaillée et correcte. En effet, cette analyse implique de comprendre le point de vue de chaque partie ainsi que le contexte dans lequel la procédure s'est réalisée. C'est pourquoi la recherche au centre de cet article vise à construire un graphe de connaissances basé sur l'ensemble de ces affaires judiciaires, enregistrées en Chine : "The Judicial Case Knowledge Graph" ou JCKG. Ce graphe est construit en utilisant des LLMs et des modèles de graph embedding. Un LLM (Large Language Model) est un modèle d'intelligence artificielle qui est capable de comprendre, manipuler et produire du texte en langage naturel. Les modèles de graph embedding sont des modèles qui permettent de représenter des données d'un graphe de connaissances sous forme de vecteurs. Cette approche est particulièrement utile dans le cas où nous voudrions effectuer de la prédiction ou de la classification sur ces données en utilisant des modèles de machine learning. Au cours de l'article, plusieurs étapes sont présentées pour démontrer la technique utilisée dans la création de ce graphe de connaissances. Tout d'abord, le chercheur à définit à la main les différents concepts et relations importantes que l'on retrouve dans des affaires judiciaires. Par exemple, un procès s'est effectué au sein d'un organe

judiciaire, il est donc lié à celui-ci (concept et relation "Court"). L'auteur a ensuite utilisé un ensemble de documents légaux annotés des concepts et relations importants afin d'entraîner le modèle LLM. Lors de cette étape, les données ont été "nettoyées" et standardisées afin de garantir un résultat de prédiction optimal. Par exemple, les acteurs non-importants ont été retirés du document. Après l'entraînement du modèle, des données judiciaires non-annotées ont été utilisées afin de tester le modèle et discuter de sa capacité à identifier les concepts et relations au sein de nouveaux documents judiciaires. A la fin, le résultat de cette prédiction est présenté sous forme d'une entité du graphe de connaissances. Un exemple de résultat pour un document légal est montré à la figure 1.

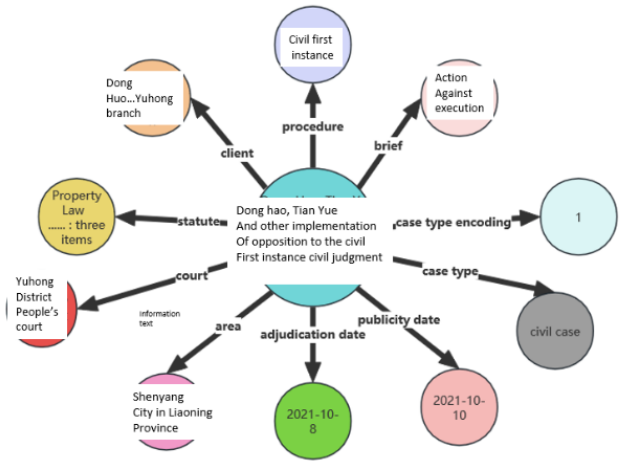


Figure 1 : Un exemple d'une entité dans le graphe de connaissances JCKG

Une fois le graphe de connaissances construit, l'auteur a testé plusieurs modèles de type "graph embedding" dans le but de faire de la prédiction de liens (link prediction). Cela signifie qu'à partir du graphe résultant des étapes précédentes, un algorithme va être appliqué pour prédire les relations manquantes entre plusieurs noeuds qui n'ont pas été explicitement définies dans le graphe, mais qui sont probablement pertinentes ou logiques. Pour ce faire, l'auteur a testé trois approches différentes : les algorithmes TransE, ConvE et pRotatE. Finalement, le modèle ConvE a montré de bonnes performances sur le jeu de données JCKG, grâce à sa capacité à gérer la sparsité présente dans les données du graphe. En revanche, les modèles TransE et pRotatE ont eu des performances plus variables, illustrant la complexité structurelle unique de ce jeu de données. Cette complexité peut s'expliquer par la nature multifactorielle des données juridiques, rendant difficile la capture de corrélations claires et cohérentes entre les différentes informations. Finalement, l'auteur aboutit à la construction d'un graphe de connaissances comprenant 32 498 triplets, couvrant 8 031 entités et répartis sur 10 types de relations.

Cette étude présente des contributions intéressantes, mais elle soulève également certaines interrogations, notamment sur la manière dont le graphe a été construit. En effet, bien que les concepts et les relations ont été clairement définies, l'auteur ne donne pas beaucoup d'indications sur le type de LLM utilisé lors de l'extraction de concepts et de relations sur les nouvelles données judiciaires. Il est alors compliqué de se faire une idée quant à la fiabilité des données extraites et du modèle LLM en général. De plus, la sparsité des données est une limite qui a été abordée dans l'article. En effet, comme chaque document judiciaire possède une struture unique et variable, il est compliqué de capturer un modèle d'embedding particulier qui arrive toujours a définir des relations entre concepts de manière fiable. Cela peut expliquer pourquoi le modèle n'atteint pas toujours une fiabilité optimale. Cependant, l'article propose une approche innovante pour modéliser les jugements sous forme de graphe. Bien que cette technique puisse être perfectionnée en ce qui concerne la récupération et la génération des données, elle présente une solution concrète à une modélisation plus intuitive et facile d'utilisation de textes légaux. Cette solution pourrait ensuite être utilisée dans des cas d'utilisations différents comme la recherche et la recommandation de documents légaux.

3 Construction d'un graphe de connaissances juridiques pour la recommandation d'articles avec une approche RAG

Dans cette seconde section, nous présenterons l'article *Leverage Knowledge Graph and Large Language Model for Law Article Recommendation : A Case Study of Chinese Criminal Law* (Yongming Chen and al, 2024)[3]. La problématique relevée dans cet article est similaire à celle discutée dans l'article précédent : il est nécessaire d'utiliser les technologies avancées d'aujourd'hui pour permettre de proposer des systèmes plus performants liés à la documentation juridique. Un aspect novateur en lien avec cette problématique est la création de systèmes de recommandation de lois pour les juristes. Cependant, ces systèmes existants ne sont pas assez puissants puisqu'ils se basent uniquement sur les critères d'identification des lois comme leur identifiants, leurs domaines, etc. et non à leur signification sémantique. Cet aspect implique que ces systèmes ne sont pas assez fiables et qu'ils nécessitent d'être révisés pour atteindre de meilleures performances. Une solution proposée est l'utilisation de LLMs pour interpréter au mieux le sens de chaque document juridique. Cependant, étant donné que les LLMs sont sujets aux hallucinations, cet article propose une approche de type RAG (Retrieval Augmented Generation), qui combine la capacité d'interprétation sémantique du LLM avec les connaissances additionnelles issues d'un graphe de données représentant des articles, dans le but d'obtenir des résultats plus fiables.

La solution proposée par cet article est développée en plusieurs étapes principales. En utilisant un LLM, les chercheurs ont d'abord construit deux graphes de connaissances distincts : un graphe regroupant des affaires judiciaires (Adjudicated Cases Knowledge Graph (ACKG)) et un graphe regroupant un ensemble de lois (Law Article Knowledge Graph (LAKG)). Pour chacun, le LLM a identifié les entités et les relations importantes définissant le texte judiciaire. A la fin du processus, 7 types d'entités et de relations ont été trouvées. Parmi elles, nous pouvons retrouver par exemple l'entité "Article original" et la relation "Agree with" qui lie une un article à plusieurs points-clés avec lesquels il est en accord. Ces graphes ont ensuite été regroupés pour former le Case-Enhanced Law Article Knowledge Graph (CLAKG). Ce graphe complet contient alors

toutes les affaires et articles de lois qui ont été trouvés lors de l'étape précédente, et qui servira de base de données lors de la recommandation d'articles.

Une fois le graphe complété, les chercheurs se sont ensuite penchés sur la création du framework de recommandation d'articles. Ce framework suit un processus particulier : l'utilisateur entre les informations principales concernant une nouvelle affaire judiciaire (le délit, les acteurs, etc.). Un LLM va ensuite analyser le document et tenter de regrouper ses éléments importants. Ces informations vont ensuite être utilisées dans un modèle de Graph Embedding pour regrouper les noeuds d'affaires juridiques du graphe CLAKG les plus similaires à l'affaire mise en input. Ensuite, pour chacune de ces affaires, l'algorithme parcours les noeuds d'information-clés de chaque affaire et la relation "key" qui lie les informations aux principes de droit, puis la relation "Applicable law" pour récupérer la loi applicable. Un exemple de noeud du graphe CLAKG est affiché dans la figure 2.

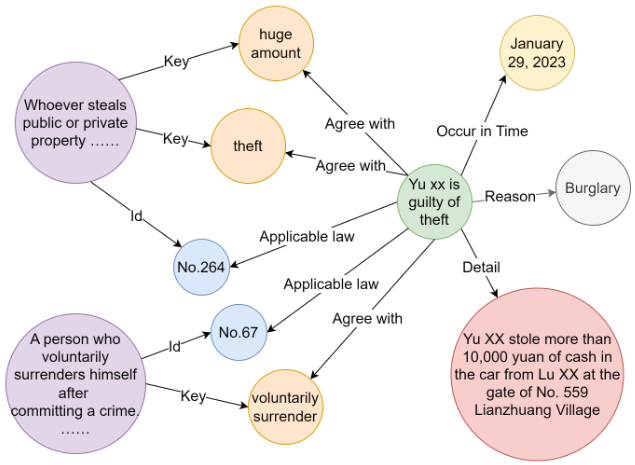


Figure 2 : Un exemple d'un noeud dans le graphe juridique CLAKG

Finalement, le graphe regroupe un total de 1.170 documents judiciaires. Ces données ont été divisées en ensemble de test et d'entraînement afin de statuer sur la qualité de prédiction du système. Après l'avoir testé en le comparant aux modèles BERT, ChatGPT-4, et des combinaisons de LLMs avec et sans l'appui de CLAKG, les chercheurs ont conclus sur l'efficacité du modèle qui est toujours plus haute en combinant le LLM ChatGPT-4 et le graphe de connaissance CLAKG, avec un taux de précision de 0.694.

J'ai trouvé que cet article était particulièrement bien structuré et développé. En effet, chaque section explique de manière claire et détaillée les différentes étapes du processus de création du framework. Aussi, les résultats présentés nous permettent d'avoir un avis honnête sur l'efficacité du système. Les auteurs ont utilisé plusieurs métriques d'évaluation et ont présenté les résultats ainsi que les erreurs de manière transparente et rigoureuse. Ici, les résultats sont prometteurs et les erreurs sont soulignées par les auteurs qui proposent également des explications à ces inexactitudes. Cependant, je pense que la présentation de plusieurs études de cas aurait renforcé la confiance dans les résultats, car une seule ne suffit pas pour évaluer pleinement l'efficacité du système. En inclure davantage aurait également permis de mieux comprendre les points d'amélioration possibles du système.

Finalement, les chercheurs ont présenté une approche robuste et fiable de système de recommandation d'articles de loi pour des affaires légales. Ce système pourra être amélioré dans le futur notamment en incluant plus de données d'entraînement et en le testant à partir d'autres modèles de LLM.

4 Combinaison des approches text-based et network-based dans la recommandation d'affaires judiciaires

Dans cette troisième section, nous traiterons l'article *A Heterogeneous Graph Based on Legal Documents and Legal Statute Hierarchy for Chinese Legal Case Retrieval* (Mengzhe HEI and al, 2024)[1]. L'objectif poursuivi au cours de cette étude est de concevoir un système de recommandation de documents légaux. Cet objectif est similaire à celui poursuivi au cours de l'étude précédente mais l'approche utilisée par les auteurs de celui-ci est différente. En effet, l'idée ici est de combiner les informations textuelles et topologiques des divers documents judiciaires afin de créer un système robuste qui génère des propositions de cas similaires. Le système fonctionne en plusieurs étapes : pour une nouvelle affaire judiciaire, on utilise d'abord un algorithme de prédiction d'articles de lois liés à cette affaire, puis on lance un deuxième algorithme qui, en fonction du contenu de l'affaire et des lois en relation, trouve un ensemble de cas similaires à retourner à l'utilisateur.

Ce processus se base sur un graphe de connaissances hétérogène nommé LeDSGra. Ce graphe contient un ensemble d'affaires judiciaires liées aux articles auxquels elles font référence. Le graphe contient également la structure suivant laquelle les articles de lois et les documents légaux sont organisés selon le code des affaires judiciaires chinois. Par exemple, les lois sont regroupées dans des sections, qui elles-mêmes font partie de chapitres. Cette structure, expliquée sous forme de schéma, se trouve à la figure 3. La prédiction d'affaires similaires pour un nouveau document légal se déroule de la manière suivante : tout d'abord, le nouveau document est transformé en noeud vectoriel séparé du graphe LeDSGra, utilisant des technologies de graph embedding. Avant de l'incorporer au graphe, ce noeud est utilisé dans un algorithme de recherche d'articles de lois, afin de trouver les articles en lien avec ce document. Cette recherche est effectuée en extrayant les charges de l'affaire, charges sur lesquelles se base l'algorithme pour trouver les lois qui s'y appliquent de manière efficace et fiable. Une fois les articles trouvés, le vecteur du noeud comporte des entités sur les informations textuelles importantes du document ainsi que sur celles des articles liés. Le noeud est alors ajouté au graphe.

Suite à cette étape, le regroupement des documents similaires est effectué en lançant une technique de prédiction de lien (link prediction) entre le noeud et ses voisins dans le graphe. Pour cela, les auteurs utilisent des méthodes de prédiction en se basant sur les métapaths du graphe. Un métapath est une séquence spécifique de relations et de types de nœuds dans un graphe hétérogène, conçue pour capturer des schémas ou des relations particulières (comme la similarité entre deux cas juridiques qui citent le même article de loi

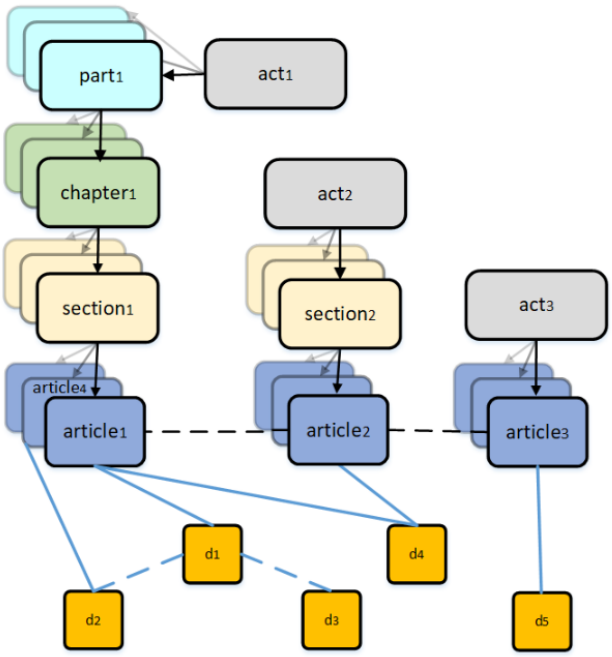


Figure 3 : Structure du graphe de connaissances hétérogène LeDSGra

ou des articles similaires) en suivant des chemins définis reliant les nœuds. Cela permet de capturer des similarités entre différentes ressources du graphes qui étaient initialement cachées. 4 types de métapaths ont été définit par les auteurs comme par exemple le métapath P1 "document-article-document" qui décrit le cas où deux documents citent le même article. En combinant les différents métapaths, il est possible d'analyser en détails le graphe notamment en observant les diverses sections et articles qui relient les noeuds du graphe. La similarité entre les noeuds du graphe à travers ces métapaths est calculée par le LLM ce qui permet d'aboutir à une liste de cas juridiques pertinents.

Ce système permet de combiner le contenu textuel des documents qui est souvent riche en informations importantes et l'approche plus structurée offerte par le graphe de connaissances. Cette approche permet d'offrir un système plus robuste et complet, et moins apte à donner de fausses informations. À la fin, les chercheurs ont évalué leur solution à l'aide de différentes métriques et en la comparant à divers modèles, tels que BERT seul et Hier-SPCNet, un algorithme basé uniquement sur la structure organisationnelle des documents juridiques. Ils ont également réalisé des tests ablatifs en retirant certains composants du système, comme des métapaths spécifiques, ou en limitant l'analyse aux informations provenant uniquement du graphe ou du modèle de langage (LLM). Ces évaluations approfondies offrent une vision claire des contributions de chaque élément et renforcent la crédibilité des résultats obtenus. C'est finalement le modèle présenté, combinant BERT et MLP qui obtient la meilleure fiabilité avec un score de 0.867.

J'ai trouvé que cet article est très complet et offre une approche encore plus poussée et solide pour le thème de recommandation de documents légaux. Bien que l'approche basée sur des LLMs pour l'intégration de ces documents est semblable aux techniques employées dans les études précédentes, l'idée d'avoir intégré une analyse des métapaths offre un soutient solide pour analyser les noeuds de documents similaires au cas actuel. La présence de nombreux tests sur divers modèles et données permet de comprendre en quoi ce modèle est plus utile et puissant que d'autres ce qui limite la pensée que les résultats du système sont biaisés. Cependant, le modèle présenté exploite une quantité importante de données pour représenter chaque noeud, en intégrant à la fois les informations textuelles des documents et les données associées aux articles de loi. Cela entraîne la génération d'un grand nombre de vecteurs multidimensionnels, rendant le modèle particulièrement complexe. Une solution devra être envisagée pour réduire cette complexité, notamment dans le cas de graphes contenant de grandes quantités de données. Cette limitation est illustrée par les tests effectués, qui se basent uniquement sur deux textes de lois chinois. Cela suggère que, dans son état actuel, le modèle reste trop complexe pour intégrer des structures provenant d'un plus large éventail de législations.

5 Conclusion

Cet état de l'art nous a permis d'avoir une vue d'ensemble des différentes applications des graphes de connaissances dans le domaine juridique. Bien que le but final des systèmes développés dans chaque étude diffère, nous avons vu que chaque étude s'est penchée sur la construction de ces graphes en y intégrant un ensemble de documents juridiques et/ou de lois. Cela permet de regrouper les ressources en des systèmes plus structurés et complets qui facilitent la restitution d'informations. Nous avons également vu que les graphes de connaissances sont toujours associés à des techniques d'intelligence artificielle, notamment des LLMs et des modèles de graph embedding. Nous pouvons souligner une similarité dans l'utilisation des LLMs pour extraire des informations des documents légaux, dans le but de construire le graphe[2][3] ou pour analyser les documents d'input au système [3][1]. Aussi, les trois travaux ont utilisé des techniques de graph embedding dans le but d'améliorer la structure des graphes en ajoutant des liens cachés.

Cependant, les travaux divergent dans l'application de ces techniques d'IA et dans la conception du graphe. D'abord, les chercheurs du premier article[2], à la différence des autres, ont établis la liste de concepts et de relations à la main quand les autres l'ont fait en utilisant des LLMs. Ensuite, bien que la prédiction de liens est un élément commun aux trois recherches, elle a été produite différemment puisque contrairement aux deux premiers travaux où cette tâche était effectuée sur l'ensemble du graphe, l'approche de LeDSGra [1] repose sur l'utilisation de patterns de métapaths prédéfinis. De plus, les articles montrent une évolution progressive vers l'intégration de techniques de plus en plus avancées et de combinaisons d'algorithmes d'IA, visant à concevoir des systèmes toujours plus robustes. On le voit notamment en comparant le premier travail qui utilise un seul LLM pour créer le graphe et faire la prédiction de lien[2], le deuxième qui ajoute une dimension nouvelle avec l'appui d'un graphe de lois en plus de celui des affaires juridiques[3], et le troisième qui utilise non seulement deux bases de connaissances distinctes (articles de loi et affaires) mais aussi la structure des lois applicables [1].

Finalement, bien que ces trois études partagent une idée globale similaire et exploitent des technologies comparables, elles diffèrent dans leur manière d'appliquer ces technologies ainsi que dans la complexité et le degré de complétude de leurs systèmes.

Références

[1] MENGZHE HEI , QINGBAO LIU , SHENG ZHANG , HONGLIN SHI, JIASHUN DUAN, AND XIN ZHANG 2024. A Heterogeneous Graph Based on Legal Documents and Legal Statute Hierarchy for Chinese Legal Case Retrieval. (2024).

[2] Yicheng Shen, East China University of Political Science and Law 2024. Construction of Knowledge Graph of Judicial Case Based on LLMs and Embedding Models. *2024 IEEE 2nd International Conference on Sensors, Electronics and Computer Engineering (ICSECE)* (2024).

[3] Yongming Chen, Miner Chen, Ye Zhu, Juan Pei, Siyu Chen, Yu Zhou, Yi Wang, Yifan Zhou, Hao Li, and Songan Zhang, Global Institute of Future Technology 2024. Leverage Knowledge Graph and Large Language Model for Law Article Recommendation : A Case Study of Chinese Criminal Law. (2024).